


Student Stress, Sleep & Screen Time


Proyecto de Aprendizaje de Máquina

Santiago Sepúlveda Blanco · Vivian Yulitza Ramírez · Carlos David Herrera



Objetivo del proyecto

Analizar patrones en estudiantes a partir de hábitos diarios y características personales para clasificar o agrupar su nivel de estrés.



Idea central: comparar si los algoritmos supervisados y no supervisados capturan patrones relacionados con el estrés estudiantil.

Descripción general

500

Registros

10

Columnas

stress_level

Variable objetivo

El dataset reúne información de estudiantes y hábitos asociados al bienestar, el sueño, el tiempo en pantalla y la presión académica.

Ejemplos de variables

sleep_hours
screen_time_hours
study_hours
academic_pressure
caffeine_intake

Muestra de columnas

age	gender	sleep_hours
22	Female	5.9
25	Male	5.9
23	Male	8.0

Clases de stress_level:
Low · Medium · High

Tipos de variables

Variables numéricas

age
sleep_hours
screen_time_hours
study_hours
caffeine_intake

Variables categóricas

gender
physical_activity
academic_pressure
stress_level

Preparación usada en los modelos:

Las variables categóricas se transformaron a valores numéricos con `pd.factorize()`.

Revisión inicial del dataset

500

Filas

10

Columnas

0

Valores nulos

Limpieza inicial

1. Cargar datos
2. Revisar `info()` y `describe()`
3. Validar nulos
4. Codificar categóricas
5. Separar X e y

Hallazgos principales

El dataset no requirió imputación de nulos.
Se identificaron variables numéricas y categóricas.
`student_id` se consideró identificador y no predictor.
`stress_level` se tomó como variable objetivo.

Estadísticas y distribución de estrés

21.53

Edad promedio

6.55 h


Sueño promedio

7.11 h


Pantalla promedio

5.02 h

Estudio promedio




Distribución de stress_level



Distribución de horas de sueño

Detección de anomalías

Se revisaron posibles valores atípicos en variables numéricas mediante boxplots.




Boxplots de variables numéricas

Resultado

No se observaron outliers relevantes.
Se continuó con el dataset completo.
La etapa posterior se centró en
codificación y partición de datos.

Sueño vs tiempo en pantalla



Relación entre screen_time_hours y sleep_hours

Lectura de la gráfica

Los puntos representan estudiantes. El color indica el nivel de estrés. La visualización muestra patrones generales, aunque no separaciones perfectas.

Esta exploración sirvió como base para entrenar modelos de clasificación.

Preparación para clasificación supervisada

Objetivo: predecir stress_level usando las demás variables del dataset.

Eliminar

student_id

Codificar

factorize()

Separar

X / y

Particionar

80% train · 20% test

Con esta preparación se entrenaron modelos que aprenden a clasificar cada estudiante en Low, Medium o High.

Modelos supervisados entrenados

Decision Tree

Parámetro evaluado: max_depth

Random Forest

Parámetro evaluado: n_estimators

SVM

Parámetro evaluado: kernels: linear · poly · rbf

Deep Learning


Parámetro evaluado: 3 · 6 · 10 capas

Todos los modelos se compararon usando accuracy sobre datos de prueba.

Resultados supervisados


Modelo	Accuracy
Decision Tree	1.0000
Random Forest	0.9600
SVM RBF	0.9500
Deep Learning	≈0.9500

Mejor resultado observado: Decision Tree



Preparación para aprendizaje no supervisado

En esta etapa ya no se entrena para predecir una etiqueta. Se busca observar cómo se agrupan los datos.



(500, 8)

Shape escalado

(500, 2)

Shape PCA

Reducción dimensional con PCA

PCA se usó para convertir 8 variables predictoras en 2 componentes principales.

8 variables

Entrada

2 componentes

Salida

Motivo

Visualizar los datos en dos dimensiones.
Facilitar la comparación de clases originales y clusters.
Usar los componentes como entrada para KMeans y DBSCAN.

Código clave

```
pca = PCA(n_components=2,  
whiten=True)  
X_pca =  
pca.fit_transform(X_scaled)
```

Resultado: X PCA = (500, 2)

KMeans

3


n_clusters

stress_level

Referencia

Justificación

El dataset tiene 3 clases: Low, Medium y High. KMeans requiere definir el número de clusters. Sirve para comparar grupos contra las clases reales.



Comparación visual: original, KMeans y DBSCAN

DBSCAN

DBSCAN agrupa por densidad y puede marcar puntos como ruido.

0.3

eps

4

min_samples

3

Clusters

0.056

Ruido

28

Puntos ruido

Criterio usado


Buscar clusters cercanos a las 3 clases reales.
Mantener bajo el número de puntos como ruido.
No elegir solo el menor ruido, porque puede producir un único cluster.

Score usado en el notebook:
 $\text{abs}(\text{clusters} - \text{n_clusters}) + \text{ruido}$

Comparación general y conclusiones

Conclusiones principales

Los modelos supervisados fueron los más efectivos para clasificar `stress_level`.
Decision Tree obtuvo el mejor resultado en el notebook.
PCA permitió visualizar los datos en 2 dimensiones.
KMeans agrupó en 3 clusters definidos.
DBSCAN encontró 3 clusters y detectó puntos de ruido.



Original / KMeans / DBSCAN

Resultado final: el enfoque supervisado fue más adecuado para predicción; el no supervisado sirvió para explorar agrupaciones y visualizar patrones.